

Bitácora de trabajo: recuperación de lecturas no humanas desde BAM WGS

Ariadna Badia

2026-06-04

Bitácora de trabajo: recuperación de lecturas no humanas desde BAM WGS

Día 1 — Exploración inicial y decisiones metodológicas

Objetivo del día

Explorar los archivos disponibles de WGS de melanoma acral.

Punto de partida

Me dí cuenta que los datos disponibles no son FASTQ crudos, son archivos BAM ya alineados al genoma humano de referencia GRCh38 + decoy + HLA y están en la ruta:

```
/mnt/data/droble/backup/acral_mexican_wgs/
```

Inicialmente pensé que, al estar los BAMs alineados a humano, las lecturas microbianas podrían haberse perdido. Sin embargo, entendí que un BAM puede conservar lecturas que no mapearon a humano. Estas lecturas quedan marcadas con el flag 4 y pueden verse con **samtools**.

Ejemplo piloto, estando en:

```
/mnt/data/sur/users/abadia/microbiome_acral_test/
```

Cargo:

```
module load samtools/1.22.1
```

Tomo una muestra y aplico:

```
samtools view -b -f 4 /mnt/data/droble/backup/acral_mexican_wgs/3165_PD60843a/mapped_sample/HUMAN_GRCh38
```

Para saber cuántas lecturas hay:

```
samtools view -c PD60843a_unmapped.bam
```

Resultado: 1,895,260 reads

De las reads totales.

Que vi con:

```
samtools view -c /mnt/data/droble/backup/acral_mexican_wgs/3165_PD60843a/mapped_sample/HUMAN_GRCh38_full_analysis_set
```

Día 2 — Extracción de reads no mapeadas y generación de FASTQ piloto

Para observar a qué microbios pertenecen esas reads, primero necesito preparar las lecturas para el clasificador. La mayoría de las herramientas de microbioma esperan como entrada FASTQ.

Objetivo del día

Extraer las lecturas no mapeadas de la muestra PD60843a y convertirlas a FASTQ.

Directorio de trabajo

```
/mnt/data/sur/users/abadia/microbiome_acral_test/
```

Extracción de reads no mapeadas

La extracción se hizo con un job.

```
nano extract_unmapped.sh
```

Dentro del script:

```
#!/bin/bash
#SBATCH --job-name=extract_unmapped
#SBATCH --cpus-per-task=4
#SBATCH --mem=16G
#SBATCH --output=slurm-%j.out

module load samtools/1.22.1

samtools view -b -f 4 \
/mnt/data/droble/backup/acral_mexican_wgs/3165_PD60843a/mapped_sample/HUMAN_GRCh38_full_analysis_set_p
> /mnt/data/sur/users/abadia/microbiome_acral_test/PD60843a_unmapped.bam
```

Doy permisos:

```
chmod +x extract_unmapped.sh
```

El job se mandó con:

```
sbatch extract_unmapped.sh
```

Job ID:

```
204219
```

Para ver si seguía corriendo, monitoreaba con:

```
squeue -j 204219
```

Archivo generado:

```
PD60843a_unmapped.bam
```

Ruta:

```
/mnt/data/sur/users/abadia/microbiome_acral_test/PD60843a_unmapped.bam
```

Verificación:

```
samtools quickcheck PD60843a_unmapped.bam  
echo $?
```

Resultado:

```
0
```

Significa que el BAM generado estaba correcto.

Conteo de lecturas:

```
samtools view -c PD60843a_unmapped.bam
```

Resultado:

```
1895260
```

Se recuperaron 1,895,260 lecturas no mapeadas a humano.

Conversión de BAM no mapeado a FASTQ

El archivo PD60843a_unmapped.bam se convirtió a FASTQ con:

```
samtools fastq PD60843a_unmapped.bam > PD60843a_unmapped.fastq
```

Archivos generados:

```
PD60843a_unmapped.bam  
PD60843a_unmapped.fastq
```

Tamaño del FASTQ:

```
ls -lh PD60843a_unmapped.fastq
```

Resultado:

```
630M
```

Número de líneas:

```
wc -l PD60843a_unmapped.fastq
```

Resultado:

```
7581040
```

Como cada read en FASTQ ocupa 4 líneas:

```
7581040 / 4 = 1895260 reads
```

Esto coincide con el conteo del BAM no mapeado.

Instalar Kraken ¿o ya está instalado?

Ahora necesito la herramienta de clasificación taxonómica, consideré utilizar Kraken2, por que es muy utilizado y clasifica rápido.

Antes de intentar instalar Kraken2, revisé si ya estaba disponible como módulo del sistema:

```
module avail kraken
```

Resultado:

```
kraken/2.1.3  
kraken/2.1.6 (D)
```

O sea ya esta instalado en el cluster, por lo que no es necesario realizar una instalación local.

Posteriormente cargué el módulo:

```
module load kraken/2.1.6
```

y confirmé que Kraken2 estaba disponible ejecutando:

```
kraken2 --help
```

La herramienta requiere también de una base de datos taxonómica para poder clasificar lecturas. Por lo que intenté localizar una base de datos ya existente dentro del cluster buscando archivos que pudieran estar en una base para Kraken2:

```
find /mnt/data -type f -name "hash.k2d" 2>/dev/null
```

También busqué directorios relacionados con Kraken:

```
find /mnt/data -type d -iname "*kraken*" 2>/dev/null
```

Después de varias búsquedas extensas no encontré ninguna base de datos Kraken utilizable para el análisis.

Construcción de la base de datos Kraken

Primero creé un directorio para almacenar la base:

```
mkdir -p /mnt/data/sur/users/abadia/kraken_db
```

Posteriormente elaboré un script para mandar job:

```
nano build_kraken_standard.sh
```

Con esto dentro:

```
#!/bin/bash
#SBATCH --job-name=build_kraken_db
#SBATCH --cpus-per-task=16
#SBATCH --mem=128G
#SBATCH --time=2-00:00:00
#SBATCH --output=build_kraken_%j.out
#SBATCH --error=build_kraken_%j.err

module load kraken/2.1.6

DB=/mnt/data/sur/users/abadia/kraken_db/standard
mkdir -p $DB

kraken2-build --standard --threads 16 --db $DB
```

y lo mandé:

```
sbatch build_kraken_standard.sh
```

Slurm asignó:

```
Job ID: 207013
```

Conversión de BAM completo a FASTQ pareado

Después pensé que una limitación era que si una lectura microbiana mapea parcialmente a humano o tiene baja calidad de mapeo, podría no aparecer como **unmapped**. Por eso, extraer solo reads con flag 4 es una primera aproximación, pero no necesariamente recupera toda la señal microbiana posible.

Si tuviera los datos crudos(FASTQ) podría aplicar los filtros de alineamiento que yo considere necesarios.

Se supone que los BAM deberían contener las lecturas originales + la información de alineamiento; y en teoría al convertir de BAM a FASTQ debería encontrar lo mismo que en un FASTQ original. Para ver si mi teoría es cierta lo voy a convertir:

Lo mandé en job:

```
nano bam_to_fastq_PD60843a.sh
```

script:

```
#!/bin/bash
#SBATCH --job-name=bam2fq_PD60843a
#SBATCH --cpus-per-task=8
#SBATCH --mem=32G
#SBATCH --time=24:00:00
#SBATCH --output=bam2fq_%j.out
#SBATCH --error=bam2fq_%j.err

module load samtools/1.22.1

BAM=/mnt/data/droble/backup/acral_mexican_wgs/3165_PD60843a/mapped_sample/HUMAN_GRCh38_full_analysis_s

samtools fastq \
-1 /mnt/data/sur/users/abadia/PD60843a_R1.fastq \
-2 /mnt/data/sur/users/abadia/PD60843a_R2.fastq \
-O /dev/null \
-s /dev/null \
$BAM
```

Revisar flagstat y stats

Pensando bien, todavía no entiendo bien qué contiene el BAM. Necesito saber el número total de lecturas, porcentaje de alineamiento, duplicados, longitud de lectura y otras métricas de calidad:

```
nano qc_bam_PD60843a.sh
chmod +x qc_bam_PD60843a.sh
sbatch qc_bam_PD60843a.sh
```

Script:

```
#!/bin/bash
#SBATCH --job-name=qc_PD60843a
#SBATCH --cpus-per-task=4
#SBATCH --mem=16G
#SBATCH --output=qc_PD60843a_%j.out
#SBATCH --error=qc_PD60843a_%j.err

module load samtools/1.22.1

BAM=/mnt/data/droble/backup/acral_mexican_wgs/3165_PD60843a/mapped_sample/HUMAN_GRCh38_full_analysis_s

samtools flagstat $BAM > /mnt/data/sur/users/abadia/microbiome_acral_test/PD60843a.flagstat

samtools stats $BAM > /mnt/data/sur/users/abadia/microbiome_acral_test/PD60843a.stats
```

Mañana revisaré el output de los jobs.